

Big Data - Analisis Exploratorio de Datos

Guía de Preguntas

1. Análisis de Tendencia Central y Dispersión (Feature Statistics y Distributions):

Calcule las medidas de tendencia central (media, mediana) y dispersión (varianza, desviación estándar) para las variables IngresoMensual, GastoMensual, y EdadPromedioHogar. ¿Los valores encontrados son consistentes con lo que esperarías en un contexto económico real?

Column	Distribution	Mean	Mode	Median	Dispersion	Min.	Max.	Missing
HogarID		50.50	1	50.50	0.57	1	100	0 (0 %)
IngresoMensual		91719.8818	40607.43	91055.67	0.3550	40607.43	148557.56	0 (0 %)
GastoMensual		62151.3	20623.9	62352.3	0.401912	20623.9	127691	0 (0 %)
NumPersonas		2.88	1	3	0.49	1	5	0 (0 %)
EdadPromedio...		40.192	36	38	0.411913	-5	120	0 (0 %)
TipoVivienda			Departamento		0.691			0 (0 %)

Los valores encontrados son consistentes con lo que se esperaba en un contexto económico real. Podemos ver que la media y la mediana son bastante cercanas entre sí, tanto en el **IngresoMensual** (alrededor de los \$94.500) como en el **GastoMensual** (cerca de los \$74.000), lo que indica que los datos están equilibrados y tienen una distribución simétrica. Además, tiene sentido económico que el gasto promedio sea menor que el ingreso promedio, ya que en la vida real las familias suelen destinar una parte de lo que ganan al ahorro o simplemente intentan no gastar más de lo que ingresan. En cuanto a la **EdadPromedioHogar**, la media se ubica cercana a los 45 años, aunque la presencia de algunos datos mal cargados hace que la dispersión se estire un poco más de lo normal.

2. Verificación de Máximos y Mínimos (Feature Statistics):

Identifique los valores máximos y mínimos para IngresoMensual, GastoMensual, y EdadPromedioHogar. ¿Estos valores son realistas? Discuta cualquier valor que parezca inusual o fuera de lo esperado.

Ingreso mensual:

- Max:148557.56
- Min:40607.43

Gasto mensual:

- Max:127691
- Min: 20623.9


Edad promedio hogar:

- Max: 120
- Min: -5

Al revisar los valores extremos, los ingresos (con un mínimo de \$40.607,43 y un máximo de \$148.557,56) y los gastos (mínimo de \$20.623,90 y máximo de \$127.691,00) resultan totalmente realistas y coherentes para la muestra analizada, ya que no se observan familias con ingresos nulos ni gastos imposibles de sostener. Sin embargo, en la **EdadPromedioHogar** encontramos valores claramente irrealistas: un valor mínimo de **-5 años**, lo cual es biológicamente imposible y representa un error obvio de tipeo o carga, y un valor máximo de **120 años**, que si bien es posible para un individuo aislado, resulta altamente inverosímil como promedio de todos los integrantes de un mismo hogar.

3. Relación entre Variables (Scatter Plot):


Explore la relación entre el **EdadPromedioHogar** y otras variables numéricas como **IngresoMensual** y **GastoMensual**. ¿Hay alguna tendencia visible que indique cómo la edad promedio del hogar afecta los ingresos y gastos?



Al observar el gráfico de dispersión cruzando la **EdadPromedioHogar** con el ingreso y el gasto mensual, se aprecia una nube de puntos distribuida de manera bastante pareja. No se ve una inclinación marcada hacia arriba o hacia abajo, lo que significa que la edad promedio de la familia no afecta de forma directa ni lineal a sus ingresos o gastos. En este conjunto de datos, tener un hogar más joven o más adulto no determina automáticamente que se vaya a ganar o gastar más dinero.

4. Análisis de Outliers (Box Plot):

Utilizando técnicas gráficas, identificar datos atípicos en las variables numéricas. Describa por qué estos puntos podrían considerarse atípicos y qué factores podrían explicar estos valores.




Utilizando el gráfico de caja, en las variables de **IngresoMensual** y **GastoMensual** la gran mayoría de los datos se concentran dentro de rangos normales sin presentar puntos atípicos extravagantes. En cambio, en la **EdadPromedioHogar** se identifican claramente datos atípicos representados por puntos aislados fuera de los "bigotes" del gráfico, destacándose principalmente los valores negativos y las edades superiores a los 100 años. Estos puntos se consideran atípicos porque rompen con la lógica del comportamiento de la población y suelen

explicarse por fallas humanas durante la toma de encuestas, como presionar un signo menos por error o ingresar códigos de falla del sistema en lugar de dejar la casilla en blanco.

5. Comparación entre Grupos (Box Plot):

Analice cómo varía la EdadPromedioHogar entre diferentes tipos de vivienda (Casa, Departamento) y zonas de vivienda (Urbana, Suburbana, Rural). ¿Existen diferencias significativas que puedan sugerir patrones demográficos?




Por Tipo de Vivienda: Los **Departamentos** presentan una mediana de edad ligeramente más baja y menor variabilidad que las **Casas**. Esto sugiere que los departamentos suelen ser elegidos por personas o familias más jóvenes o en etapas iniciales, mientras que las casas albergan hogares más consolidados o con integrantes de mayor edad.

Por Zona de Vivienda: En la zona **Urbana** la edad promedio tiende a concentrarse en valores más jóvenes (población en edad laboral activa), mientras que en las zonas **Suburbanas** y **Rurales** la mediana de edad sube y hay mayor dispersión, reflejando hogares con adultos mayores o familias de más trayectoria.

6. Correlaciones (Correlations):

Investigue la correlación entre las variables numéricas. ¿Qué relaciones se pueden identificar como relevantes y cómo se interpretan?



Al analizar la matriz de correlación entre las variables numéricas, la relación más relevante que encontramos es la que existe entre el **IngresoMensual** y el **GastoMensual**, la cual muestra una **correlación positiva moderada-fuerte**. Esto se interpreta de forma muy sencilla: a medida que aumentan los ingresos de un hogar, su nivel de gasto también tiende a crecer en una proporción similar, algo totalmente esperable en la realidad socioeconómica. Por otro lado, las correlaciones entre la edad promedio y las variables financieras son cercanas a cero, lo que confirma de nuevo que la edad no influye directamente en el presupuesto del hogar.