Informe: Feature Engineering en Orange (Census Income)

22 de octubre de 2026

1. Carga y preparación inicial

Para la ejercitación usamos Orange Data Mining con el dataset Adult Census Income, que reúne información demográfica, educativa y laboral de personas. El objetivo es predecir si una persona gana más de USD 50.000 al año a partir de esas características.

El dataset tiene 48.842 registros y 15 variables. La variable objetivo (Target) es `income`, con dos categorías:

- `<=50K` : ingresos anuales de hasta USD 50.000.
- `>50K` : ingresos anuales superiores a USD 50.000.

Cargamos los datos con el widget Datasets, que ya deja `income` como Target categórico.

2. Modelo base (Baseline)

Antes de crear variables nuevas, medimos el rendimiento de tres algoritmos con las columnas originales del dataset:

- Logistic Regression
- Neural Network
- Random Forest

Para compararlos usamos el widget Test & Score con validación cruzada de 10 particiones (10-fold Cross Validation) estratificada. Estos fueron los resultados:

Model	AUC	CA	F1	Prec	Recall	MCC
Logistic Regression	0.902	0.850	0.844	0.843	0.850	0.563
Neural Network	0.885	0.838	0.836	0.834	0.838	0.544
Random Forest	0.895	0.853	0.849	0.847	0.853	0.578

Resultados del baseline en Test & Score

Análisis de resultados

Los tres modelos tienen un rendimiento parecido. Logistic Regression logró el mayor AUC (0,902), es decir, la mejor capacidad para separar a quienes superan los USD 50.000 de quienes no. Random Forest obtuvo la mayor exactitud (85,3 %) y el mejor F1-Score (0,849). Neural Network quedó apenas por debajo en las tres métricas (AUC 0,885, Accuracy 83,8 %, F1 0,836).

- Logistic Regression y Random Forest fueron los mejores modelos de partida.

- Estos valores son la referencia para saber si las variables nuevas mejoran las predicciones.

3. Feature Engineering

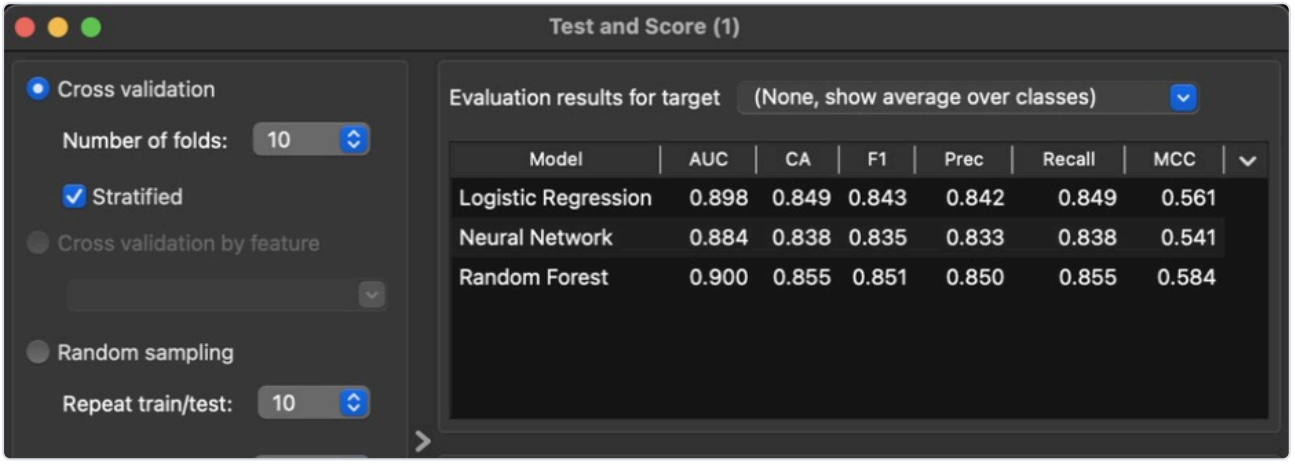
Objetivo: sumar información que los modelos no ven directamente en las columnas originales, usando transformaciones simples y fáciles de explicar.

Usamos el widget Formula para crear cuatro variables nuevas. Para conservar el baseline, conectamos Formula a un segundo Test & Score, con los mismos tres modelos y la misma validación, y así pudimos comparar ambos resultados.

1. **net_capital_gain:** ganancia neta de capital, es decir, las ganancias menos las pérdidas.
   - Fórmula: `capital_gain - capital_loss`
2. **capital_per_hour:** retorno de capital en relación con las horas trabajadas por semana.
   - Fórmula: `capital_gain / (hours_per_week + 1)` (el +1 evita dividir por cero)
3. **annual_hours:** horas trabajadas en un año, suponiendo 52 semanas.
   - Fórmula: `hours_per_week * 52`
4. **is_overwork** (categórica): indica si la persona trabaja más de 45 horas por semana.
   - Fórmula: `1 if hours_per_week > 45 else 0`
   - Valor 1: más de 45 horas. Valor 0: 45 horas o menos.

4. Evaluación del impacto de las nuevas variables

Random Forest fue el único modelo que mejoró: subió su AUC de 0,895 a 0,900, su Accuracy de 0,853 a 0,855 y su F1-Score de 0,849 a 0,851. Logistic Regression y Neural Network quedaron iguales o con pequeñas bajas (el AUC pasó de 0,902 a 0,898 y de 0,885 a 0,884). Esto muestra que sumar variables no garantiza una mejora en todos los modelos y que el efecto depende del algoritmo. Las diferencias son de entre 0,001 y 0,005 y no hicimos un test estadístico, por lo que conviene leerlas como una tendencia.



Resultados con Feature Engineering en Test & Score

Resumen

Modelo	AUC (Baseline)	AUC (Con Feature Eng.)	Accuracy (Baseline)	Accuracy (Con Feature Eng.)	F1-Score (Baseline)	F1-Score (Con Feature Eng.)
Logistic Regression	0,902	0,898	0,850	0,849	0,844	0,843
Neural Network	0,885	0,884	0,838	0,838	0,836	0,835
Random Forest	0,895	0,900	0,853	0,855	0,849	0,851

5. Preguntas de reflexión de negocio

1) Impacto en los modelos: ¿Cuál de los algoritmos se benefició más de las nuevas variables y por qué?

Random Forest fue el que más se benefició, con mejoras leves en AUC (+0,005), Accuracy (+0,002) y F1-Score (+0,002). Nuestra hipótesis, que no comprobamos con otro experimento, es que los árboles toman decisiones con cortes sobre una variable a la vez y les cuesta armar por sí solos un cociente como capital_per_hour, así que recibirlo ya calculado les aporta información nueva. En Logistic Regression, net_capital_gain es una combinación lineal de dos columnas que el modelo ya tenía y annual_hours es hours_per_week por una constante, así que no suman nada que no pudiera representar. Neural Network apenas se movió, algo esperable en un modelo que ya puede aprender combinaciones entre variables.

2) Interpretabilidad y negocio: ¿Por qué net_capital_gain puede ser más valiosa para marketing o riesgo que capital-gain y capital-loss por separado?

Resume en un solo indicador el resultado financiero real de una persona: quien tiene ganancias altas y pérdidas igual de altas no es más solvente que quien no tiene movimientos. Para marketing facilita armar segmentos simples y explicables, y para riesgo es más fácil de auditar y de justificar ante un cliente o un regulador. La contrapartida es que se pierde la diferencia entre un inversor muy activo y alguien sin actividad, por lo que conviene conservar también las variables originales.

3) Ética y sesgo: Si se usara is_overwork para aprobar créditos automáticamente, ¿qué sesgos o riesgos se podrían introducir?

Trabajar más de 45 horas semanales no implica necesariamente mayor capacidad de pago: puede venir de varios empleos mal pagos o de informalidad. Además, la variable se asocia con género, edad y ocupación, y perjudicaría a quienes trabajan menos por cuidar a otras personas o por salud, lo que sería discriminación indirecta. El umbral de 45 horas es arbitrario, es autoinformado y el dataset es un censo de EE.UU. de 1994, así que sus patrones pueden no valer hoy ni en otro país. Por eso no debería ser un criterio único ni automático, y las decisiones necesitarían explicación y revisión humana.

4) Propuesta innovadora: Una variable adicional que ayude a predecir si un usuario gana más de 50K.

Proponemos potential_experience, que estima los años potenciales de experiencia laboral.

- Fórmula: `age - education_num - 6`
- Intuición de negocio: el ingreso suele crecer con los años trabajados, y esta variable combina edad y educación de una forma que ninguna de las dos captura por separado. Dos personas de 40 años, una con 9 años de estudio y otra con 16, tienen trayectorias muy distintas.
- Habría que acotarla en cero para evitar valores negativos y comprobar su utilidad evaluando el modelo, porque todavía no la probamos en Orange.