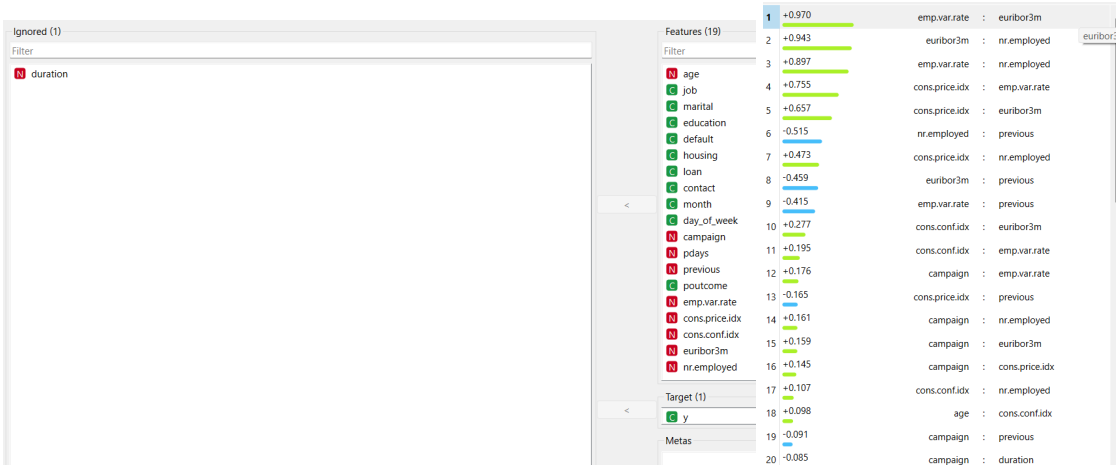
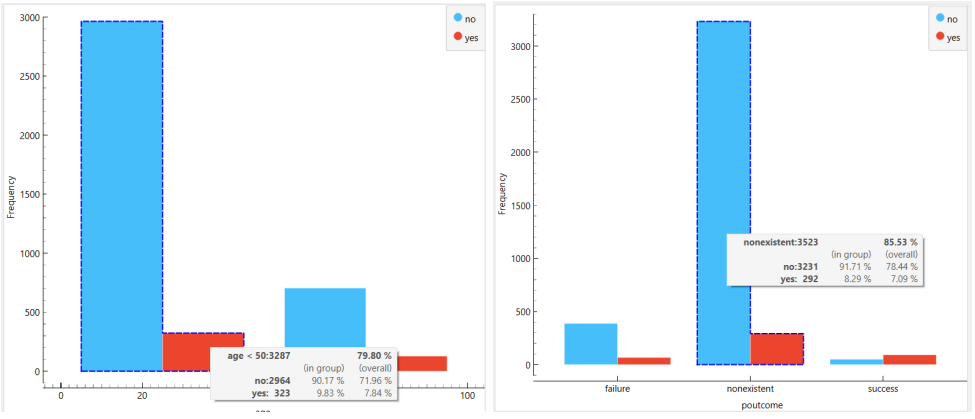
Carga de datos y asignación de roles: Se cargó el dataset Bank Marketing en Orange, configurando correctamente la variable y como la clase o variable objetivo (Target) y manteniendo el resto de las columnas como características (Features), a excepción de la variable duration que fue excluida (Ignore) para evitar sesgos de información en un escenario de predicción real.



Análisis Exploratorio de Datos:

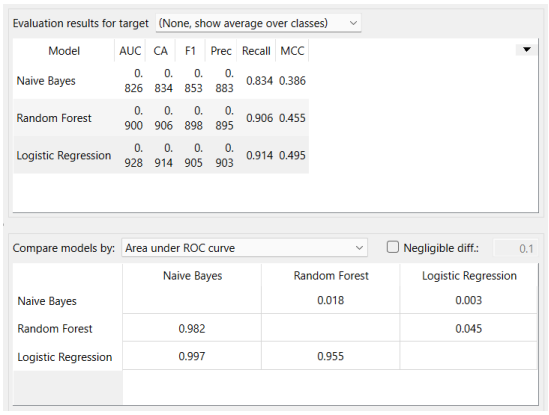
- Variable Objetivo (y): Se observa un marcado desbalance en la clase objetivo, donde la gran mayoría de los registros corresponden a clientes que no se suscribieron al depósito a plazo fijo (no, representados en barras azules), frente a una minoría que sí lo hizo (yes, barras rojas).
- Variable Predictora age (Edad): La distribución etaria muestra que la mayor concentración de clientes se encuentra en rangos de edad menores a 50 años (agrupando la mayor frecuencia tanto de rechazos como de aceptaciones), con una presencia decreciente a medida que aumenta la edad.
- Variable Predictora poutcome (Resultado previo): La categoría predominante es con creces nonexistent (campañas anteriores inexistentes para la mayoría de los clientes). No obstante, es interesante notar que la categoría success (éxito previo) muestra una proporción relativamente alta de suscripciones positivas (yes) en relación con su volumen total, lo que la posiciona como un fuerte indicador predictivo.



Comparativa Global de Rendimiento

- La **Regresión Logística** se posicionó como el modelo superior en todas las métricas principales (AUC: 0.928, CA: 0.914, F1-score: 0.905, MCC: 0.495). Esto demuestra que un modelo lineal regularizado es altamente efectivo para este tipo de dataset de marketing bancario, permitiendo capturar de forma sólida las relaciones entre los factores socioeconómicos/demográficos y la probabilidad de contratación del depósito a plazo fijo.
- **Random Forest** obtuvo un desempeño secundario pero muy cercano (AUC: 0.900, F1: 0.898). Aunque los árboles de decisión son excelentes capturando interacciones no lineales complejas, en este caso particular sin la variable duration (y tras la continuización/codificación de categóricas), la Regresión Logística logró un margen de separación ligeramente mejor.

- **Naive Bayes** registró los valores más bajos en casi todos los indicadores (AUC: 0.826, CA: 0.834). Esto se debe principalmente al supuesto de independencia condicional entre las variables predictoras que asume este algoritmo. En este dataset existen variables fuertemente correlacionadas (como las variables macroeconómicas emp.var.rate, euribor3m, nr.employed o cons.price.idx), lo cual viola dicha suposición y degrada la capacidad predictiva de Naive Bayes.



Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Naive Bayes	0.826	0.834	0.853	0.883	0.834	0.386
Random Forest	0.900	0.906	0.898	0.895	0.906	0.455
Logistic Regression	0.928	0.914	0.905	0.903	0.914	0.495

Compare models by: Area under ROC curve — Negligible diff.: 0.1

	Naive Bayes	Random Forest	Logistic Regression
Naive Bayes		0.018	0.003
Random Forest	0.982		0.045
Logistic Regression	0.997	0.955	

Análisis de la Matriz de Confusión (Regresión Logística)

A partir de la matriz de confusión obtenida para el modelo de Regresión Logística, se identifican los siguientes valores absolutos:

- Verdaderos Negativos (TN): 2853 (clientes reales no clasificados correctamente como no).
- Falsos Positivos (FP): 77 (clientes reales no clasificados erróneamente como yes).
- Falsos Negativos (FN): 208 (clientes reales yes clasificados erróneamente como no).
- Verdaderos Positivos (TP): 158 (clientes reales yes clasificados correctamente como yes).

Análisis de la Curva ROC

Análisis del Trade-off: Al observar las gráficas en el widget ROC Analysis, la curva correspondiente a Logistic Regression (y de cerca Random Forest) se eleva de manera más pronunciada hacia la esquina superior izquierda en comparación con Naive Bayes.

Esto significa que la Regresión Logística logra una alta Tasa de Verdaderos Positivos (TPR) manteniendo una Tasa de Falsos Positivos (FPR) muy baja en sus umbrales de decisión óptimos, consolidándose como el clasificador con el mejor rendimiento general y la curva ROC más dominante.

