

❖❖ Guía de Práctica: Introducción a BigQuery

Objetivo: Comprender cómo funciona un Data Warehouse moderno procesando datos públicos y propios a gran escala.

1. ¿Qué estamos haciendo realmente?

En esta práctica, vas a utilizar **BigQuery**. A diferencia de una base de datos tradicional (como MySQL), BigQuery es un **Data Warehouse** basado en la nube.

- **No hay servidores:** No instalas nada. Google pone miles de CPUs a trabajar para ti.
- **Escalabilidad:** Puede analizar Terabytes de datos en segundos.
- **Separación de datos:** Aprenderás la diferencia entre usar datos que otros comparten (Public Datasets) y subir tus propios datos.

2. Fase 1: Explorar un "Data Lake" Público (Tareas 1 y 2)

BigQuery aloja cientos de datasets gratuitos. Esto simula un escenario real donde tu empresa consume datos externos (clima, censos, tendencias) para enriquecer su propia información.

- **¿Qué aprenderás?** A conectar BigQuery con fuentes de datos externas y usar SQL para extraer valor inmediato.
- **Concepto clave: Procesamiento Distribuido.** Cuando ejecutas el **SELECT**, BigQuery escanea millones de filas de nombres de bebés en segundos usando la infraestructura masiva de Google.

3. Fase 2: Crear tu propia infraestructura (Tareas 3, 4 y 5)

Aquí dejas de ser un espectador y te conviertes en un **Data Engineer**. Vas a simular la ingesta de datos (Ingestion).

- **El archivo (**yob2014.txt**):** Es un archivo **CSV** (texto plano). En el mundo real, esto podría ser un log de ventas o registros de sensores.
- **El Dataset (**babynames**):** Piensa en el Dataset como una **carpeta o contenedor**. Es donde organizas tus tablas y defines quién tiene permiso para verlas.
- **El Esquema (**Schema**):** Es la estructura. Le dices a BigQuery: "La primera columna es texto (nombre), la segunda es texto (género) y la tercera es un número (conteo)". Sin

esquema, los datos son solo texto sin sentido.

4. Fase 3: Análisis y Resultados (Tarea 6)

Una vez que los datos están "limpios" y cargados en tu tabla, ejecutas una consulta final.

- **¿Qué aprenderás?** A cruzar criterios (filtros como `WHERE gender = 'M'`) y ordenar resultados para obtener **insights** (información accionable).
- **Diferencia clave:** Verás que la sintaxis para consultar tu propia tabla es casi idéntica a la de los datos públicos; lo único que cambia es la "ruta" del archivo.

EJERCICIOS

? Preguntas de Comprensión

1. Sobre la primera consulta (Los nombres públicos)

Pregunta: En la Tarea 2, ejecutaste una consulta sobre millones de registros de nombres en EE.UU. ¿Qué fue lo que "hizo" realmente esa instrucción de texto (la query) con toda esa montaña de datos?

- **A.** Copió todos los datos a tu computadora para que los pudieras ver.
- **B.** Le pidió a los servidores de Google que buscaran, sumaran y ordenaran los datos allá en la nube, entregándote solo el "top 10" final.
- **C.** Borró los nombres menos comunes para que la tabla fuera más pequeña.

2. Sobre la carga de datos (El archivo de 2014)

Pregunta: En la Tarea 5, subiste un archivo de texto (`yob2014.txt`) y creaste una tabla. ¿Por qué es necesario este paso antes de poder hacer preguntas (queries) a los datos?

Respuesta:

Se necesita subir el archivo y crear una tabla porque BigQuery necesita tener los datos organizados para después poder hacer consultas. Es decir, una vez que los datos están

subidos y estructurados se pueden hacer queries para preguntar y analizar informacion.

3. Sobre la diferencia entre lo "Público" y lo "Propio"

Pregunta: Hiciste consultas sobre un dataset de Google ([bigquery-public-data](#)) y sobre uno que creaste tú ([babynames](#)). ¿Cuál es la principal ventaja de tener ambos mundos en la misma herramienta?

Respuesta :

La principal ventaja es que podemos trabajar con datos públicos y con propios datos desde la misma herramienta. Se pueden usar datasets públicos para obtener información y después compararla o combinarla con otros datos propios. Esto puede facilitar mucho el análisis porque no se tiene que utilizar diferentes herramientas para cada tipo de dato.

💡💡 Pregunta final!

En la última tarea, la query les trajo los nombres de hombres más populares. Si quisieran saber cuáles fueron los 20 nombres de **mujeres** más usados en 2014, ¿Cómo sería la query (consulta SQL)?

```
SELECT
  name, count
FROM
  `babynames.names_2014`
WHERE
  gender = 'F'
ORDER BY count DESC
LIMIT 20
```

Link al Laboratorio:

https://www.cloudskillsboost.google/focuses/3616?catalog_rank=%7B%22rank%22%3A8%2C%22num_filters%22%3A1%2C%22has_search%22%3Atrue%7D&parent=catalog&search_id=52306923